


O que fazer com a saída do **hifiasm**? Quero poder alinhar/mapear a um genoma de referência e detectar variantes estruturais e/ou SNP.

Ótima pergunta. A saída do **hifiasm** é uma montagem *de novo* do genoma da amostra — ou seja, uma reconstrução das sequências genômicas dessa amostra, **sem depender diretamente da referência**. A partir disso, você pode seguir dois fluxos:

🔗 Duas opções principais de análise

1. Detectar variantes estruturais (SVs):

Use a montagem `*.p_ctg.fa` como *query* e alinhe contra o **genoma de referência** (ex: ARS-UCD1.2 ou ARS-UCD2.0) para detectar **SVs**:




Ferramentas:

- `minimap2`: alinhamento da montagem ao genoma de referência
- `sniffles2`, `SVIM`, `cuteSV`: chamadas de **SVs**
- `SyRI`: detectar rearranjos estruturais entre genomas montados

2. Chamar SNPs/INDELs diretamente dos dados de leitura (recomendado para SNPs):

Se o foco for **SNPs**, é melhor **não usar a montagem do hifiasm**, mas sim:



Ou seja:

- Mapeie os **reads** diretamente ao genoma de referência com `minimap2`
- Faça chamadas de variantes com `DeepVariant`, `Clair3`, `GATK`, etc.

Fluxo para variantes estruturais usando montagem

1. Alinhar montagem ao genoma de referência:

Bash

```
minimap2 -ax asm5 reference.fa assembly.p_ctg.fa > aligned.sam
samtools view -Sb aligned.sam | samtools sort -o aligned.sorted.bam
samtools index aligned.sorted.bam
```

2. Detectar SVs:

Bash

```
sniffles --input aligned.sorted.bam --vcf sv_calls.vcf --threads 16
```

Você também pode usar:

Bash

```
cuteSV aligned.sorted.bam reference.fa sv_cutesv.vcf tmp/ --threads 16
```

✓ Dicas importantes:

- **SVs**: use montagem (`p_ctg.fa`)
- **SNPs**: use os *reads*, não a montagem
- Combine os dois métodos se quiser um panorama completo
- Se quiser comparar montagem x referência de forma mais global (ex: inversões, translocações), use:
 - `nucmer` + `delta-filter` + `dnadiff` (do `MUMmer`)
 - `SyRI` (ótimo para comparações genoma-genoma)

Se quiser, posso montar um **pipeline completo (bash ou Snakemake)** para:

- SVs a partir da montagem (`p_ctg.fa`)
- SNPs a partir dos *reads*
- Análise integrada das variantes

Você já tem uma referência específica (ARS-UCD2.0?) e preferência por alguma ferramenta de chamada de variante?

Se todos os seus arquivos `.tsv` têm o mesmo cabeçalho, você pode fazer o *merge* facilmente no terminal usando `awk` ou `cat`, garantindo que o cabeçalho apareça apenas uma vez.

Por exemplo:

Bash

```
awk 'FNR==1 && NR!=1 { next; } { print }' /caminho/para/pasta/*.tsv > merged.tsv
```

Explicação:

- `FNR==1 && NR!=1 { next; }` → ignora o cabeçalho (`FNR==1`) de todos os arquivos exceto o primeiro (`NR!=1`).
- `{ print }` → imprime todas as linhas (dados + cabeçalho do primeiro arquivo).

Ou usando `tail` + `cat`:

Bash

```
head -n 1 /caminho/para/pasta/arquivo1.tsv > merged.tsv
for file in /caminho/para/pasta/*.tsv; do
    tail -n +2 "$file" >> merged.tsv
done
```

Se preferir fazer em **Python**:

Python

Executar

```
import pandas as pd
import glob

arquivos = glob.glob("/caminho/para/pasta/*.tsv")
df = pd.concat([pd.read_csv(f, sep="\t") for f in arquivos], ignore_index=True)
df.to_csv("merged.tsv", sep="\t", index=False)
```

Se quiser, eu já posso montar um script para rodar no seu cluster e juntar todos os `.tsv` de forma automática.

sex., 15 de ago. às 5:39

Liste todas as colunas obtidas com o comando `"seqkit stats -a -T COWADAPT_*_filt.fq.gz > fastq_stats.tsv"` e o que elas representam. Quais delas são úteis para se comparar a qualidade de diferentes amostras?

Aqui estão as colunas geradas pelo comando:

Bash

```
seqkit stats -a -T COWADAPT_*_filt.fq.gz > fastq_stats.tsv
```

e o significado de cada uma, além de uma orientação sobre quais são mais relevantes para comparar qualidade entre amostras.